

לעמוד 316

316163260

2 תרגום - IML

(1) נניח $\ker(X) \subseteq \ker(X^T X)$. יהי $0 \neq u \in \ker(X)$ ונראה כי $u \in \ker(X^T X)$.
 $X^T X u = X^T 0 = 0$

נניח $\ker(X^T X) \subseteq \ker(X)$. יהי $0 \neq u \in \ker(X^T X)$ ונראה כי $u \in \ker(X)$.

$$u^T X^T X u = u^T 0 = 0$$

⇓

$$(X u)^T X u = 0 \Rightarrow \langle X u, X u \rangle = 0$$

ומכאן קיבלנו כי $X u = 0$ ונראה כי $u \in \ker(X)$.

(2) יהי $v \in \operatorname{Im}(A^T)$ ונראה כי $v \in \ker(A)$. נניח $A^T u = v$ ונראה כי $A v = 0$.

$$\langle v, w \rangle = \langle A^T u, w \rangle = (A^T u)^T w = u^T A w = u^T 0 = 0$$

$$\operatorname{Im}(A^T) \subseteq \ker(A)^\perp$$

יהי $v \in \ker(A)^\perp$ ונראה כי $v \in \operatorname{Im}(A^T)$. נניח $A^T u = v$ ונראה כי $A v = 0$.

$$\langle v, w \rangle = \langle A^T u, w \rangle = (A^T u)^T w = u^T A w = u^T 0 = 0$$

$$\langle A^T u, w \rangle = u^T A w = 0$$

(3) X אינה הפיכה ולכן $\operatorname{Im}(X) \neq \mathbb{R}^n$. נניח $y \in \operatorname{Im}(X)$ ונראה כי $y \in \ker(X^T)^\perp$.

נניח $y \in \operatorname{Im}(X)$ ונראה כי $y \in \ker(X^T)^\perp$.

$$X w = y \Rightarrow \langle y, z \rangle = \langle X w, z \rangle = w^T X^T z = 0 \Rightarrow y \in \ker(X^T)^\perp$$

הוא הפתרון למשוואה, ואם \vec{e} הוא וקטור, אז $\vec{e} \in \text{Im}(X)$.

(4) אם $X^T X$ הפיכה:

$$X^T X w = X^T y \Rightarrow (X^T X)^{-1} X^T X w = (X^T X)^{-1} X^T y \Rightarrow$$

$$w = (X^T X)^{-1} X^T y$$

אם $X^T X$ אינה הפיכה:

כאשר נבחר $X^T y \in \ker(X^T X)^\perp$, נהיה $\forall v \in \ker(X^T X)$ נכון (1) המקרה

כלומר, $Xv = 0$ ולכן, $v \in \ker(X)$.

$$\langle X^T y | v \rangle = (X^T y)^T v = y^T Xv = 0$$

קבלנו ל- $X^T y$ מאונך ל- $\ker(X^T X)$ (3) נכון. האינו שמקרה זה אמולאב

ע' איננו מתקבל.

(5) אם נשלב P הוא סכום של מטריצות סימטריות, ואם הוא סימטרי גם כן.

(2) המקרה:

$$P v_j = \left(\sum_{i=1}^k v_i v_i^T \right) v_j = \sum_{i=1}^k v_i v_i^T v_j = \sum_{i=1}^k v_i \delta_{ij} = v_j$$

(2) יהי $v \in V$, $v = \sum_{i=1}^k c_i v_i$ (כל $c_i \in \mathbb{R}$)

$$P v = P \sum_{i=1}^k c_i v_i = \sum_{i=1}^k P c_i v_i = \sum_{i=1}^k c_i P v_i = \sum_{i=1}^k c_i v_i = v$$

(2.180)

(3) נניח P כפונקציה EVD בעל D היא מטריצה היתרית של P (החזק).

$$P^2 = U D U^T U D U^T = U D D U^T = U D U^T = P$$

$$(I-P)P = IP - PP = P - P^2 = P - P = 0 \quad (6)$$

$$X^+ y = (X^T X)^{-1} X^T y \quad \text{אם } X^T X \text{ אינו סינגולרי} \quad (6)$$

$$(X^T X)^{-1} X^T = X^+ \quad \text{אם } X^T X \text{ אינו סינגולרי}$$

$$(X^T X)^{-1} X^T = ((U \Sigma V^T)^T (U \Sigma V^T))^{-1} (U \Sigma V^T)^T =$$

$$(V \Sigma^T U^T U \Sigma V^T)^{-1} (U \Sigma V^T)^T = (V \Sigma^T \Sigma V^T)^{-1} V \Sigma^T U^T =$$

$$(V^T)^{-1} (\Sigma^T \Sigma)^{-1} V^{-1} V \Sigma^T U^T =$$

$$V (\underbrace{\Sigma^T \Sigma}_{I})^{-1} \Sigma^T U^T = V \Sigma^T U^T = X^+$$

$$\text{ההצגה } X \text{ היא המצאה } \text{span}\{x_1, \dots, x_m\} \text{ של } \mathbb{R}^d \quad (7)$$

$$\mathbb{R}^d = \text{span}\{x_1, \dots, x_m\} \quad X^T X \text{ אינו סינגולרי}$$

$$X^T X \text{ אינו סינגולרי, } M_{d \times d} \ni X^T X \text{ - אינו סינגולרי, } \text{rank}(X^T X) = d$$

$$\text{rank}(X^T X) = d$$

$$X w = y \quad X^T X \text{ אינו סינגולרי} \quad (8)$$

$$U \Sigma V^T = X \text{ היא SVD של } X$$

$$\Sigma \text{ היא מטריצה אלכסונית של הערכים הסינגולריים של } X$$

$$\text{הערכים הסינגולריים של } X \text{ הם } \sigma_1, \dots, \sigma_r$$

אנחנו רוצים לבנות U, V מהמטריצה A כך:

$$U = \begin{bmatrix} | & | & & | & | & \dots & | \\ u_1 & u_2 & & u_r & u_{r+1} & \dots & u_d \\ | & | & & | & | & \dots & | \end{bmatrix}$$

$$V = \begin{bmatrix} - & -V_1^T & - \\ & \vdots & \\ - & -V_r^T & - \\ & -V_{r+1}^T & - \\ & \vdots & \\ - & -V_m^T & - \end{bmatrix}$$

הוקטורים u_1, \dots, u_r ציבים את U של A בצורה U -
 והוקטורים v_1^T, \dots, v_r^T " " " " " " V -

הוקטורים u_{r+1}, \dots, u_d , v_{r+1}^T, \dots, v_m^T של A נבחרים כך ש- SVD
 Σ תהיה טרנספוזיט

מה שמכונה \hat{W} הוא טרנספוזיט $d, r+1, \dots$ מהוקטורים u_{r+1}, \dots, u_d

$$\bar{W} = \begin{bmatrix} \bar{w}_1 \\ \vdots \\ \bar{w}_r \\ \bar{w}_{r+1} \\ \vdots \\ \bar{w}_d \end{bmatrix}, \quad \hat{W} = \begin{bmatrix} w_1^1 \\ \vdots \\ w_r^1 \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

$$\|\hat{W}\| = \sum_{i=1}^r \hat{w}_i^2 + \sum_{i=r+1}^d 0^2 \leq \sum_{i=1}^r \bar{w}_i^2 + \sum_{i=r+1}^d \bar{w}_i^2 = \|\bar{W}\|$$

כל


עכשיו

IML – תרגיל 2 – חלק מעשי

(13)

בחרתי להפוך את zipcode ל-feature קטגוריאלי, משום שזה feature שלא יכול להיות בעל השפעה על המחיר באופן לינארי. כלומר, זה feature שיכול להשפיע על המחיר, אבל אין משמעות למספר עצמו של ה- zipcode מבחינה לינארית.

(15)

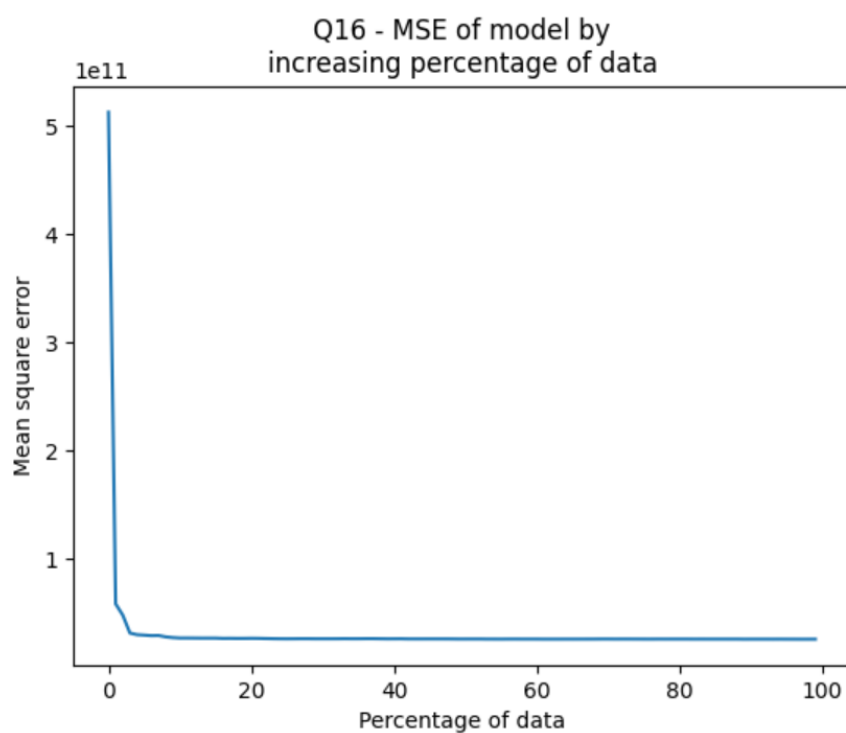


נשים לב בטבלה למטה כי 2 הערכים הסינגולריים הנמוכים ביותר הם 0, ואחרים 0.03.

84	85	86
0.03240	0.00000	0.00000

מכיוון שקיים ערך סינגולרי ששווה ל-0, המטריצה X היא לא הפיכה. כמו כן, קיים ערך סינגולרי שקרוב ל-0 (0.03), וניתן לפרש את זה כך שיש שני features שהזווית ביניהם חדה, ועל כן הם קירוב לינארי אחד של השני. זה גורר שגם אם לא היה ערך סינגולרי ששווה ל-0, המטריצה הייתה לכל הפחות "קרובה" ללהיות סינגולרית.

(16)



ניתן לראות בגרף כי ככל שמאמנים את המודל על יותר דאטה, ה- mse קטן, כלומר הדיוק עולה. נשים לב כי השיפור ברמת הדיוק קורה די מהר.

(17)

הקורלציה הכי גבוהה שנמצאה היא בין מחיר לבין sqft_living, ולכן ה- sqft_living הוא feature מועיל ומשמעותי למודל.



קורלציה נמוכה שנמצאה היא בין מחיר לבין מצב הדירה, ולכן מצב הדירה הוא feature לא מועיל ולא משמעותי למודל.

