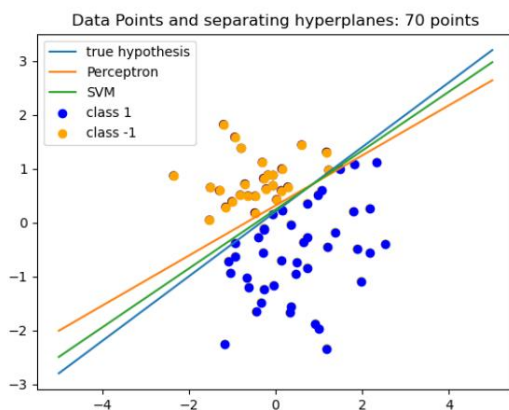


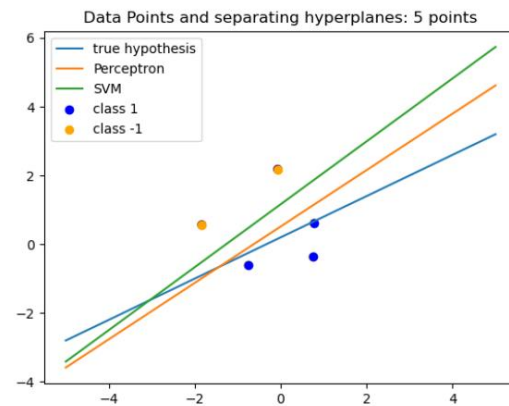
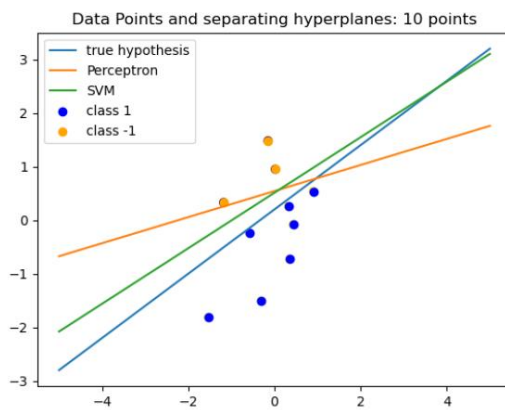
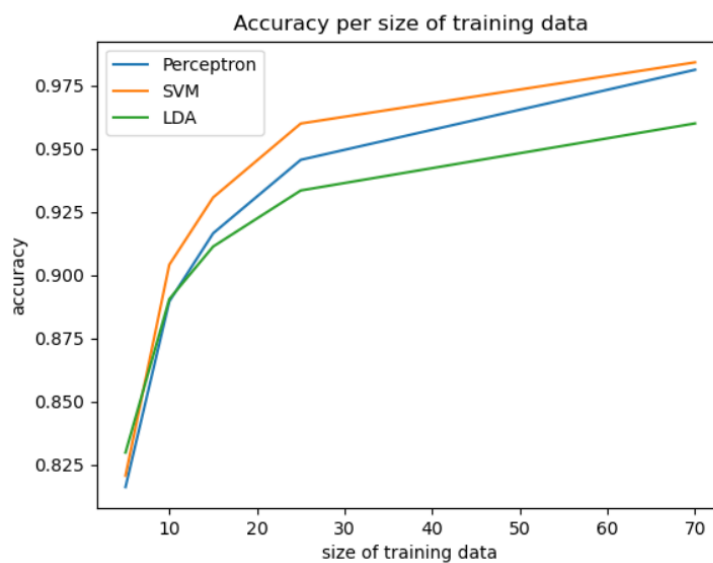


IML – תרגיל 3 – חלק מעשי

(9)





(10)



(11) ה – classifier שעשה את העבודה הכי טובה הוא ה-SVM. נזכיר שה-hard-SVM ממקסם את השוליים, ולכן מתקיימת רמה נוספת של אנליזה שמודל הפרספטרון לא לוקח בחשבון. LDA עשה את העבודה הכי פחות טובה, כי הוא מניח הנחה שלא מתקיימת בדאטה שלנו, ומשתמש בשערוכים.

(12)





logistical regression time: 0.0320210599899292 m: 50

soft svm time: 0.05595876693725586 on m: 50

decision tree time: 0.011732168197631836 on m: 50

knn time: 0.2588677549362183 on m: 50

logistical regression time: 0.027227387428283692 m: 100

soft svm time: 0.06716924190521241 on m: 100

decision tree time: 0.01156142234802246 on m: 100

knn time: 0.4352590084075928 on m: 100

logistical regression time: 0.039820923805236816 m: 300

soft svm time: 0.1008923101425171 on m: 300

decision tree time: 0.023917679786682126 on m: 300

knn time: 1.298315396308899 on m: 300

logistical regression time: 0.03851727962493897 m: 500

soft svm time: 0.09460421562194823 on m: 500

decision tree time: 0.02191664218902588 on m: 500

knn time: 1.710689787864685 on m: 500

ניתן לראות כי לכל m , לאלגוריתם ה-knn לוקח הכי הרבה זמן לרוץ. אחריו, לכל m , נמצא soft-svm מבחינת זמן ריצה. לאחר מכן, נמצא logistic regression, ואחריו decision tree, שרץ בזמן הקצר ביותר לכל m .

השתמשתי בספריית sk-learn בשביל ארבעת המודלים.

לוג בן 31

316163260

תרגיל 3 IML - חלק ת'א'א

(1) $P(X|Y) \cdot P(Y) = P(Y|X) \cdot P(X)$ כן חוק ב"ס מק"פ

$$h_D = \begin{cases} +1 & P(y=1|x) \geq \frac{1}{2} \\ -1 & \text{otherwise} \end{cases}$$

אם נסתכל:

$$P(y=1|x) = \frac{P(x|y=1) \cdot P(y=1)}{P(x)}$$

↑
ב"ס

אם הביטוי h_D מתנהג 1 סתם אז $P(y=1|x) \geq \frac{1}{2}$, אלא:

$$h_D(x) = 1$$

⇓

$$P(y=1|x) \geq \frac{1}{2}$$

⇓

$$\arg \max_{y \in \{ \pm 1 \}} \{ P(y=1|x) \} = \arg \max_{y \in \{ \pm 1 \}} \left\{ \frac{P(x|y=1) \cdot P(y=1)}{P(x)} \right\} = \checkmark$$

$$\arg \max_{y \in \{ \pm 1 \}} \{ P(x|y=1) \cdot P(y=1) \}$$

האם אכן זה המק"פ אם הביטוי h_D מתנהג -1 האם סתם? כן

$$h_D = \arg \max_{y \in \{ \pm 1 \}} \{ P(x|y) \cdot P(y) \}$$

התוצאה (2)

$$h_D(x) = \underset{y \in \{\pm 1\}}{\operatorname{argmax}} \{P(x|y) \cdot P(y)\} = \underset{y \in \{\pm 1\}}{\operatorname{argmax}} \ln \{P(x|y) \cdot P(y)\} =$$

(לפי חוקי האינדיקס)

~~$$\underset{y \in \{\pm 1\}}{\operatorname{argmax}} \{P(x|y) \cdot P(y)\}$$~~

$$\underset{y \in \{\pm 1\}}{\operatorname{argmax}} \{ \ln P(x|y) + \ln P(y) \} =$$

$$\underset{y \in \{\pm 1\}}{\operatorname{argmax}} \left\{ \ln \left(\frac{1}{(2\pi)^d \det(\Sigma)} \exp \left(-\frac{1}{2} (x - \mu_y)^T \Sigma^{-1} (x - \mu_y) \right) \right) + \ln P(y) \right\} =$$

$$\underset{y \in \{\pm 1\}}{\operatorname{argmax}} \left\{ \ln \left(\exp \left(-\frac{1}{2} (x - \mu_y)^T \Sigma^{-1} (x - \mu_y) \right) \right) + \ln P(y) \right\} =$$

$$\underset{y \in \{\pm 1\}}{\operatorname{argmax}} \left\{ -\frac{1}{2} (x - \mu_y)^T \Sigma^{-1} (x - \mu_y) + \ln P(y) \right\} =$$

$$\underset{y \in \{\pm 1\}}{\operatorname{argmax}} \left\{ -\frac{1}{2} x^T \Sigma^{-1} x + \frac{1}{2} \mu_y^T \Sigma^{-1} x + \frac{1}{2} x^T \Sigma^{-1} \mu_y - \frac{1}{2} \mu_y^T \Sigma^{-1} \mu_y + \ln P(y) \right\} =$$

$$\underset{y \in \{\pm 1\}}{\operatorname{argmax}} \left\{ x^T \Sigma^{-1} \mu_y - \frac{1}{2} \mu_y^T \Sigma^{-1} \mu_y + \ln P(y) \right\} =$$

התוצאה

$$\underset{y \in \{\pm 1\}}{\operatorname{argmax}} \{ d_y(x) \}$$

(3) סדר G נקרא עשירי, $y=1$, וזוהי ע'ע x_1, \dots, x_n בקיצור λ .

נמחק:

$$\mu_{+1} = \frac{1}{n} \sum_{i=1}^n x_i$$

$$\mu_{-1} = \frac{1}{m-n} \sum_{j=1}^{m-n} x_j$$

$$\Sigma = \frac{1}{n} \sum_{i=1}^n (x_i - \mu_i)(x_i - \mu_i)^T$$

$$P(y=1) = \frac{1}{m} \sum_{i=1}^m f(y_{i,1})$$

$$P(y=0) = \frac{1}{n} \sum_{i=1}^n \delta(y_i, 0)$$

$\therefore \frac{1}{2} \times 210 \times 2 = 210$ (4)

skoo skoo-uf le zho - false positive

skewness " " false negative

השגחה הראשונה היא הצלחה יותר, כי אם מ"ל שנות א-סכא, ע"פ
והוא חשד, יצא לתיק הסכא, שבו הממשלה יסרה, ולכן יסרה את
(המ"ל) החשד.

$$\arg \min_{(w, b)} \|w\|^2 \text{ s.t. } \forall i, y_i (\langle w, x_i \rangle + b) \geq 1: \text{hard-SVM} \rightarrow \text{"yes"} \quad (5)$$

הפרמטרים: $\alpha \in \mathbb{R}^n$, $a \in \mathbb{R}^n$, $A \in \mathbb{R}^{m \times n}$, $Q \in \mathbb{R}^{n \times n}$ סימטרית

$$\arg \min_{v \in \mathbb{R}^n} \left\{ \frac{1}{2} v^T Q v + a^T v \mid A v \leq d \right\} \quad -f$$

המשקל $a = v \cdot \frac{1}{2}$ ו- $Q = I_n$ עליון

$$\frac{1}{2} v^T Q v + a^T v = \frac{1}{2} v^T I_n v + \frac{1}{2} v^T v = v^T v = \|v\|^2$$

ואם נניסוק להחזיר $y_i (\langle w, x_i \rangle + b) \geq 1$ - δ $A_v \leq d$. אם כן:

ש"כ, A על i -ה ומה A_i כך $A \in \mathbb{R}^{nm}$ וזה, $\langle W, X_i \rangle$, $\frac{1 - by_i}{y_i}$

$$A_i = -x_{i,1} \quad \text{s.t.} \quad A = - \begin{bmatrix} x_{1,1}^T \\ \vdots \\ x_{n,1}^T \end{bmatrix}$$

$$V = (w, b)$$

$$d \in \mathbb{R}^m \quad \text{s.t.} \quad d_i = -\frac{1}{y_i}$$

⑥ י' ו' (בזכר עב; י' ה' מניח' , ואז המאמץ שלום יהיה מניח'.

דאס פארמאט פון א פונקט x_i איז (x_i, y_i) און y_i איז א פונקט פון א פונקט x_i .

$$\varepsilon_i \geq \ell^{\text{hinge}}(y_i \langle w, x_i \rangle)$$

גמול שני ע-; ימים מ'מ'א' ציין אומק"ם ש"און ממל.

המשפט הראשון של פאליס: $\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{k=1}^n f(x_k) = \int_a^b f(x) dx$ כאשר f פונקציה רציפה ו- x_k נקודות סמליות.

loss of $\psi = \ell^{\text{hinge}}(y_i; \langle w, x_i \rangle)$ $\forall i$ $\epsilon_i \geq \ell^{\text{hinge}}(y_i; \langle w, x_i \rangle)$

$\Psi \in L^2(\Omega; dx)$, $\Psi|_{\partial\Omega} = 0$. $\Delta \Psi = f$ in Ω .

האם ניתן להשתמש ב- $\epsilon_1, \dots, \epsilon_{n-1}, \psi, \epsilon_{n+1}, \dots, \epsilon_n$ כדי להוכיח את הטענה?

$$\epsilon_i = \ell^{\text{hinge}}(y_i; \langle w_i, x \rangle)$$